My Big Blue Fat Whale

项目说明 · 技术栈 / 功能 / 实现方式

版本 2.0 • 2026-10-27

一、这是什么

一个给 AI 对话装外置记忆的工具。它把长对话按「事件」归纳成第一人称的记忆，再把少量骨架带进新窗口，让对话能在上下文耗尽后继续下去。

三个直接用途：

- 续命：对话快撞上上下文上限时，把该记的带走，换个新窗口接着聊。
- 搬家：多个聊天框的内容并进同一个记忆体。
- 回想：一句话把很久以前聊过的事找回来，需要时还能翻到原话。

二、技术栈

后端

项	选型	说明
语言	Java 21	与既有项目对齐，用 record、switch 表达式等
框架	Spring Boot 3.3.5	Web / Data JPA / 定时任务
数据库	H2（文件模式）	单文件 memory.mv.db，免安装；留了 MySQL 配置开关
ORM	Hibernate 6	ddl-auto=update，加表加列不动旧数据
HTTP	RestClient	调 DeepSeek / 智谱 / DeepSeek 网页版
构建	Maven	boot 插件打可执行 jar

前端

项	选型	说明
框架	React 18.3 + TypeScript	无 UI 库，手写 CSS 变量体系
构建	Vite 6	产物打进后端 static，同源访问

样式	原生 CSS	黑金配色，无 Tailwind

桌面外壳与打包

项	选型	说明
窗口	.NET 8 WinForms + WebView2	原生窗口，内嵌 Edge 内核，不是浏览器标签页
图标	多尺寸 .ico	exe / 窗口 / 任务栏共用一张
运行时	jlink 裁剪 JRE 21	约 87 MB，用户不用装 Java
发布	dotnet publish 单文件	自包含，约 67 MB

外部服务

用途	服务	可替换性
对话 / 总结 / 事件划分	DeepSeek chat（deepseek-chat）	填任意兼容 OpenAI 协议的 key
向量	智谱 embedding-3（2048 维）	缺 key 时退化为本地哈希向量（512 维）
网页版导入	DeepSeek 网页版 v0 接口	用 userToken / cURL，只读

三、功能清单

记忆体

- 多记忆体，各自独立的对话、事件、人格锚点与统计。
- 新建、重命名、删除；导出为 .json，或从 .json 导入。

导入

来源	做法
DeepSeek Harness	读本机 ~/.dsh/sessions，列出会话直接导入
DeepSeek 网页版	填 userToken 或整段 cURL，列出会话后导入
已有记忆体	拖 .json 到窗口任意位置，或从现有记忆体复制
手动粘贴	用户/助手、User/Assistant、问/答 等格式

记忆库（两层）

- 事件记忆：一件件事的卡片，第一人称日记 + 情绪 + 关系备注 + 未完成线头。
- 对话记忆：一问一答原文，分页、关键词搜索、深度回忆。
- 事件可点开看下辖对话；可勾选两条合并；长事件自动尝试拆分。

AI 对话

- 每轮先检索当前记忆体，再把命中内容拼进 system prompt。
- 问题先经 LLM 改写（补指代、同义词）再检索。
- 每个记忆体一条独立对话线，存在本地，关窗不丢。
- 聊完的问答写回记忆体，后台继续总结、归类。

说话方式 / 人格锚点

- 从双方对话里总结语气、称呼、态度、格式习惯、禁忌。
- 可手选最多 8 条对话作为语气样例。
- 可按当前语气重写全部总结（事实不变，只改腔调）。

续命包

- 两种组装：按原文（旧版）或按事件（推荐）。
- 按事件组装 = 人格锚点 + 最近事件日记 + 事件间过渡 + 线头 + 情绪。
- 显示字数与 token 估算，附复制按钮。

四、实现方式

1. 记忆流水线

```
导入/对话 → 切分（一轮问答=一条 memories）→ 状态 pending
→ Worker 每 2 秒取 10 条 → 调模型写第一人称小记 + 关键词 + 重要度
→ 调向量接口 → 写 embedding → 状态 ready
```

Worker 是 @Scheduled 定时任务，导入接口立即返回，进度由 /api/health 的 pending 暴露。

2. 检索打分

```
query → LLM 改写 → 向量相似度 + 词面匹配 + 新近度 + 记忆强度 + 重要度
```

权重：相似度 0.68、新近度 0.16、强度 0.09、重要度 0.07、词面 0.06；半衰期 30 天。

词面匹配会扫正文（问题、答案、摘要、关键词），并对 4 字以上的原样命中直接加分——诗句、报错码、函数名这类罕见词靠它兜住。

3. 事件层

严格遵循三条规则：一条对话只属于一个事件；事件时间取该事件最早对话的时间；事件内按时间排序，事件之间也按时间排序。

首次导入 → 全量划分：按 30 轮分块，LLM 切块内事件，落库后逐事件写日记

之后新对话 → 攒 3 条归类：候选=最近 15 个事件，LLM 返回 event_id 或 new_title

失败兜底 → 归到时间最近的既有事件，标 fallback

日记由三样东西构成：发生了什么、我怎么理解他、我做了什么取舍；同时产出情绪（从→到、强度、依据）、关系备注、未完成线头、事件级向量。

4. 长事件与接缝

- 单个事件超过 50 轮：让模型试拆 2–3 段；拆不动就标记 long_running，日记改滚动式。
- 事件之间用 episode_transitions 记录过渡（隔了几天 / 话题怎么转的），归类时同一次调用顺带产出，不额外花钱。

5. 桌面壳

exe 启动 → 从 8790 找空闲端口 → 拉起 javaw（无黑窗）

→ 轮询 /api/health → 就绪后 WebView2 加载页面 → 关窗时结束子进程

后端地址由前端运行时判断：开发时（5173）指向 8787，打包后同源相对路径。

6. 关键实现细节

- 密钥运行时可改：LlmSettings 读 data/llm.json，优先级高于环境变量，保存即生效。
- 打包版禁用 .env.local 自动探测，避免把开发机上的 key 带进产品包。
- 事件重建保留人工改过的事件（edited_by_user），其余重切。
- 分页：记忆列表 30 条一页，按 offset/limit 在库层截取。

五、数据模型

表	作用	关键字段
spaces	记忆体	name, persona/style, episode_auto_rewrite
memories	对话记忆（原文）	question, answer, summary, embedding, episode_id

episodes	事件记忆	title, diary, mood_*, relation_note, open_threads, started_at, last_at
episode_transitions	事件接缝	from/to, kind, days_gap, transition_note
import_jobs	导入任务	total, done, status, ids

六、接口概览

分组	主要接口
状态	GET /api/health、GET /api/stats?spaceId=
记忆体	GET/POST /api/spaces、DELETE /api/spaces/{id}、POST /api/spaces/merge
对话记忆	GET /api/memories?spaceId=&limit=&offset=、GET/DELETE /api/memories/{id}
导入	POST /api/import、/api/web/import、/api/dsh/import、/api/deepseek/import
检索	POST /api/recall、POST /api/bundle、POST /api/chat
事件	GET /api/spaces/{id}/episodes、GET /api/episodes/{id}、POST .../partition、POST .../pack、POST /api/episodes/{id}/merge
人格	GET/POST /api/spaces/{id}/style、POST .../style/picks、POST .../restyle
模型	GET /api/llm、POST /api/llm/key、/api/llm/test、/api/llm/clear

七、目录结构

```
backend/          Spring Boot
  src/main/java/com/dayufish/
    service/      MemoryService / SummaryService / EpisodeService / StyleService ...
    web/          ApiController
    domain/       Space / Memory / Episode / EpisodeTransition
  data/memory.mv.db
```

```
frontend/          React + Vite
  src/pages/       Library / ImportPage / BundlePage / Settings / ChatPage
desktop-host/      .NET 8 WinForms + WebView2 外壳
tools/             打包与文档脚本
docs/              设计文档与手册
```

八、构建与打包

```
cd frontend && npm run build
xcopy /E /I /Y dist\* ..\backend\src\main\resources\static\
cd ..\backend && mvn -DskipTests package
jlink --add-modules ALL-MODULE-PATH --strip-debug --no-header-files \
      --no-man-pages --compress=zip-6 --output ..\build\rt
dotnet publish ../desktop-host -c Release -r win-x64 --self-contained true -o ../build/host
→ 组装：exe + app.ico + server\{runtime, app, data}
```

九、设计取舍

取舍	原因
摘要只做检索，回答用原文	摘要会丢细节，模型需要原话才能准确回答
事件是第一公民	人回忆先想起事件，再想起具体的话
单进程 + 本地 H2	单用户、绿色免安装，复制文件夹即迁移
网页版走 v0 接口	没有公开 API，只能复用其前端接口，随版本可能变动
向量缺 key 时退化	保证离线可用，只是检索精度下降

十、已知限制

- 事件粒度偏细（100 轮约 30 个事件），可手动合并。
- 长事件自动拆分缺少真实样例验证。
- 网页版接口随对方改版可能失效。
- 单用户无鉴权，只监听 127.0.0.1，不可直接暴露公网。

— 完 —